

Литература

1. Мхитарян В.С. , Архипова М.Ю. и др. Анализ данных. – М.: Издательство Юрайт, 2018. – 490 с.
2. Барсегян А.А., Куприянов М.С., Степаненко В.В., Холод И.И. Технологии анализа данных: Data Mining, Visual Mining, Text Mining, OLAP. – Санкт-Петербург: «БХВ-Петербург», 2008

Дополнительная

1. Материалы сайта **Data Mining**:
<https://intuit.ru/studies/courses/6/6/info>

Анализ данных как дисциплина

«Анализ данных» — это ровно то, что стоит в названии — анализ данных. Мы имеем данные, и мы хотим извлечь из них полезные закономерности, которые можно использовать в дальнейшем, например, для повышения эффективности бизнес-процессов, проведения каких-то исследований, планирования и так далее.

Современный специалист, чтобы быть конкурентоспособным на рынке труда, должен владеть **количественными методами анализа и прогнозирования**. Отсюда и новые, повышенные, требования к его подготовке. Жизнь подтверждает справедливость утверждения о том, что кто владеет информацией, тот владеет миром. Однако чтобы информация превратилась в знания, нужно уметь **правильно подготовить и обработать данные, владеть методами моделирования, анализа и интерпретации результатов их обработки**.

Анализ данных как научная дисциплина в системе прикладной статистики разрабатывает и систематизирует понятия, приемы, математические методы и модели, предназначенные для организации отбора из исследуемой совокупности подлежащих обследованию единиц, их стандартной записи, систематизации и обработке с целью их удобного представления и интерпретации, получения научных и практических выводов. Очевидно, что применение любого математического метода для изучения явления означает использование его формальной модели, т.е. определенной системы предпосылок и постулатов.

В данном курсе **анализ данных** рассматривается как дисциплина, основанная на статистических методах и вычислительных алгоритмах, позволяющих извлекать знания из результатов наблюдений.

В процессе анализа данных исследователь чаще всего пытается их сжать, стремясь потерять при этом как можно меньше заложенной в них полезной информации. Делается это обычно с помощью статистических методов. Сокращение объема данных достигается за счет применения двух взаимно дополняющих принципов: ***выборочного метода и свертки информации***. Первый из них декларирует отказ от всей совокупности данных (***генеральной совокупности***) в пользу специально организованной ее части — ***выборки***, а второй заменяет всю выборку ее несколькими характеристиками, например средней арифметической, дисперсией и т.д., а также результатами применения методов исследования зависимостей, снижения размерностей и классификации.

Визуальный анализ данных

Визуальный анализ данных – это процесс, в котором исследование данных происходит с помощью наглядного отображения информации. Визуальный анализ необходим для поддержки аналитической работы с данными. Цель визуального анализа – ответ на важные вопросы с использованием данных и фактов. В качестве примера рассмотрим пример визуального исследования [информации о наблюдениях НЛО](#). Для исследования, нам понадобится выбрать интересующий нас набор данных (**DataSet**). Разнообразные наборы Dataset'ы можно [скачать с сайта](#). DataSet обычно представляет собой файл с таблицей в формате JSON или CSV. Наша цель будет не получить исчерпывающие ответы на главный вопрос жизни, вселенной и всего такого, а показать простоту обработки достаточно большого объема данных. Собственно, на месте НЛО могла быть любая таблица.

И так, таблица (файл DataSet — **scrubbed.xls**) с наблюдениями имеет следующие столбцы:


- datetime — дата появления объекта;
- city — город в котором появился объект;
- state — штат;
- country — страна;
- duration (seconds) — время на которое появился объект в секундах;
- duration (hours/min) — время на которое появился объект в часах/минутах;
- shape — форма объекта;
- comments — комментарий;
- date posted — дата публикации;
- latitude — широта;
- longitude — долгота.

Построим график наблюдений по странам:




Больше всего наблюдений естественно в США. Тут ведь оно как, все **гики** (фанаты), которые следят за НЛО живут в США (скорее всего, таблица составлялась гражданами США)? Если инопланетяне действительно посещали землю в открытую, то вряд ли бы их заинтересовала одна страна, сообщение об НЛО появлялись бы из разных стран.

Интересно еще посмотреть в какое время года наблюдали больше всего объектов. Есть резонное предположение, что больше всего наблюдений в весеннее время.



Ожидалось весеннее обострение, но предположение не подтвердилось. ***Кажется теплые летние ночи и период отпусков дают о себе знать сильнее.***

Посмотрим какие формы объектов на небе видели и сколько раз.



Видим, что больше всего на небе видели просто свет, который в принципе необязательно является НЛО. Этому явлению существует внятное объяснение, например, ночное небо отражает свет от прожекторов и т.п. Также это вполне может быть северным сиянием, которое появляется не только в полярной зоне, но и в средних широтах, а изредка даже и вблизи экватора. Вообще атмосфера земли пронизана множеством излучений различной природы, электрическими и магнитными полями.

Интересно еще посмотреть среднее время, на которое в небе появлялся каждый из объектов.



Из диаграммы видим, что больше всего в небе в среднем висел конус (более 20 часов). Если покопаться в интернете, то ясно, что конусы в небе, это тоже свечение, только в виде конуса. Вероятнее всего это свет от падающих комет. Среднее время больше 20 часов — это какая-то нереальная величина. В исследуемых данных большой разброс, и вполне могла вкратиться ошибка.

Несколько очень больших, неверных значений времени появления могут существенно исказить расчет среднего значения. Поэтому при больших отклонениях, считают не среднее значение, а **медиану**.

Медиана — это некоторое число, характеризующее выборку, одна половина в выборке меньше этого числа, другая больше.



Полумесяц видели в небе чуть больше 5-ти часов. Другие объекты не надолго промелькнули в небе. Это уже наиболее достоверно.