

1. Классификация статистических данных

1.1. Критерии классификации данных

Анализ данных проводится с целью:

- **анализа и отображения** конкретной собранной информации — в этом случае говорят о статистическом описании, **описательной** (дескриптивной) **статистике** (*descriptive statistics*);
- описания всего класса явлений по имеющимся выборочным данным, характеризующим только часть этого класса. Эти задачи относятся к **аналитической статистике**.

Под **данными** (data) в статистике понимают совокупность сведений, зафиксированных на определенном носителе в форме, пригодной для их постоянного хранения, передачи и обработки.

В статистике для характеристики изучаемых объектов используются **различные типы данных**, и к каждому типу применимы свои методы их обработки. Поэтому прежде всего необходимо **определиться с их классификацией**.




Рис. 1. Классификация статистических данных по различным критериям

1.2. Классификация данных по числу переменных

В **одномерных** наборах данных у каждого наблюдения регистрируется только один признак.

В этом случае статистические методы используются для определения основных характеристик этого признака:

- расчет средних значений и показателей вариации, размаха признака;
- группировка данных и построение вариационных рядов (дискретных и интервальных);
- графическое представление данных с целью их визуализации и анализа;
- исследование различий наблюдений или групп наблюдений, требующих особого рассмотрения (задача классификации и выявления аномальных наблюдений).

Примеры одномерных данных

В качестве одномерных данных могут выступать:

- цена некоторого продукта питания в разных магазинах г. Покровска;
- динамика числа семей, нуждающихся в улучшении жилищных условий, в г. Якутск;

Пример 1

Индексы цен на первичном рынке жилья по Российской Федерации (на конец года; в % по отношению к концу предыдущего года). Данные представлены в табличной форме и в виде точечно-линейного графика (*line chart, time plot*), построенного в программе *MS Excel*.

	Индекс цен, %	Год	Индекс цен, %	Год	Индекс цен, %	Год	Индекс цен, %
1998	156,9	2003	118,8	2008	110,3	2013	104,8
1999	146,3	2004	118,5	2009	92,4	2014	105,7
2000	113,1	2005	117,5	2010	100,3		
2001	125,1	2006	147,7	2011	106,7		
2002	122,5	2007	123,4	2012	110,7		



Рассмотрим точечно-линейного график, построенный на *Питоне*:

```
# -*- coding:cp1251 -*-  
import platform  
term_enc = 'utf-8' if platform.uname()[0] == 'Linux' else 'cp1251'  
import matplotlib.pyplot as plt  
x = [1998,1999,2000,2001,2002,2003,2004,2005,2006,2007,2008,2009,2010,2011,2012,2013,2014]  
y = [156.9,146.3,113.1,125.1,122.5,118.8,118.5,117.5,147.7,123.4,110.3,92.4,100.3,106.7,110.7,104.8,105.7]  
plt.plot(x, y, color='green', marker='o', markersize=7)  
plt.xlabel('Год')  
plt.ylabel('Индекс цен, %')  
plt.title('Индексы цен на первичном рынке жилья')  
plt.grid(True)  
plt.show()
```




Пример 2

Уровень безработицы (в %, на конец месяца, в среднем за год) в России в 1994 – 2015 гг. (в 2015 г. – среднее за первые шесть месяцев). Данные представлены в табличной форме и в виде лепестковой диаграммы (*MS Excel*).

Год	Уровень безработицы, %	Год	Уровень безработицы, %	Год	Уровень безработицы, %
1994	7,39	2002	8,06	2010	7,36
1995	8,53	2003	8,63	2011	6,51
1996	9,60	2004	8,16	2012	5,45
1997	10,81	2005	7,57	2013	5,50
1998	11,86	2006	7,17	2014	5,16
1999	12,74	2007	6,13	2015	5,65
2000	10,49	2008	6,36		
2001	9,03	2009	8,38		

Безработица в России 1994-2015 гг., %



Рассмотрим лепестковую диаграмму, построенную на *Питоне*:



```
# -*- coding:cp1251 -*-
import platform
term_enc = 'utf-8' if platform.uname()[0] == 'Linux' else 'cp1251'
import numpy as np
import matplotlib.pyplot as plt
from matplotlib.patches import Patch
f = open('data.txt')
categories = [x for x in f.readline().split()]
Value1 = [float(x) for x in f.readline().split()]
categories = [*categories, categories[0]]
values_1 = [*Value1, Value1[0]]
label_loc = np.linspace(start=0, stop=2 * np.pi, num=len(categories))
fig, ax = plt.subplots(figsize=(5,5), subplot_kw=dict(polar=True))
ax.plot(label_loc, values_1, lw=2)
ax.fill(label_loc, values_1, alpha=0.3)
lines, labels = plt.thetagrids(np.degrees(label_loc), labels=categories)
ax.set_ylim(0, 14)
ax.set_yticks(np.arange(0, 14, 2))
ax.set_title('Безработица в России 1994-2015, %')
plt.show()
```

В **многомерных** (двумерных, трехмерных и т.д.) наборах данных у каждого наблюдения регистрируется несколько признаков.

Статистические методы в этом случае используются для решения задач:

- определения основных характеристик по каждому одномерному признаку;
- анализа наличия и степени зависимости между этими признаками;
- исследования вида зависимости одной переменной (результативной) от остальных (**факторных**);
- классификации наблюдений с целью получения однородных групп (**кластеров**) и выявления аномальных наблюдений;

- построения обобщающих, интегральных показателей с целью снижения размерности исходного признакового пространства;
- анализа рядов и прогнозирования (для временных данных).

Примеры многомерных данных

В качестве многомерных данных можно рассматривать следующие:


характеристика работника некоторой фирмы с помощью нескольких показателей: *заработная плата, пол, образование, стаж работы, категория работы и производительность труда;*

характеристика квартиры на рынке вторичного жилья в Якутске с помощью нескольких показателей: *стоимость квартиры, общая площадь, площадь кухни, удаленность от центра, этаж, материалы стен дома.*


Пример

Характеристика стран мира по уровню проникновения сотовой связи; ВВП, ИЧР (индекса человеческого развития). **Пузырьковая диаграмма** позволяет наглядно представить на двумерной плоскости трехмерные данные – с помощью диаметра или площади поверхности пузырьков отобразить различия в каком-либо показателе у исследуемых объектов.


Страна	Уровень проникновения сотовой связи в 2012 г.,%	ВВП на душу населения, тыс.долл.	ИЧР (2012 г.)
Гонконг	229,24	51 103	0,906
Россия	182,92	23 589	0,788
США	95,45	51 749	0,937
Гаити	59,91	1208	0,456
Испания	108,36	32 134	0,855
Вьетнам	147,66	3787	0,617



Уровень проникновения сотовой связи в 2012 г., %
(соответствует диаметру пузырьков)



Рассмотрим лепестковую диаграмму, построенную на *Питоне*:



```
# -*- coding:cp1251 -*-
import platform
term_enc = 'utf-8' if platform.uname()[0] == 'Linux' else 'cp1251'
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.patches as mpatches
plt.figure(figsize=(7,7))
x = np.array([51103, 23589, 51749, 1208, 32134, 3787])
y = np.array([0.906, 0.788, 0.937, 0.456, 0.855, 0.617])
z = np.array([229.24, 182.92, 95.45, 59.91, 108.36, 147.66])
z = z * 5
col = ['r','g','b','c','y','m']
for index, val in enumerate(z):
    color = col[index]
    plt.scatter(x[index], y[index], s=z[index], alpha=0.5, c=color)
red_patch = mpatches.Patch(color='red', label='Hong Kong - 229.24')
green_patch = mpatches.Patch(color='green', label='Russia - 182.92')
blue_patch = mpatches.Patch(color='blue', label='USA - 95.45')
aqua_patch = mpatches.Patch(color='aqua', label='Haiti - 59.91')
yellow_patch = mpatches.Patch(color='yellow', label='Spain - 108.36')
purple_patch = mpatches.Patch(color='purple', label='Vietnam - 147.66')
plt.legend(handles=[red_patch, green_patch, blue_patch, aqua_patch, yellow_patch, purple_patch])
plt.title('Уровень проникновения сотовой связи в 2012 г.,% \n(соответствует диаметру пузырьков)')
plt.xlabel('ВВП на душу населения, тыс.долл.')
plt.ylabel('Индекс человеческого развития')
plt.show()
```

1.3. Классификация данных по наличию или отсутствию упорядочения во времени

Пространственные данные — значения переменных, относящихся к однотипным объектам в один и тот же фиксированный момент времени. Они позволяют сравнить значение признака, измеренное на разных объектах исследования, сравнить эти объекты по степени проявления в них того или иного свойства и разделить все объекты в соответствии с этим на группы и категории.

Примеры пространственных данных


К пространственным данным можно отнести:

- температуру воздуха в разных городах России в определенный день.
- данные по курсам покупки и продажи определенной валюты в разных обменных пунктах города на конкретный день;
- данные по курсам покупки и продажи валюты различных стран в определенном обменном пункте города на конкретный день;

Пример

Величина прожиточного минимума (в среднем на душу населения), установленная в некоторых субъектах РФ за IV квартал 2013 г. Данные представлены в табличной форме и в виде ленточной (полосовой) диаграммы

Регион	Рублей в месяц	Регион	Рублей в месяц
Тамбовская область	5230	Московская область	8072
Пензенская область	6057	Красноярский край	8249
Астраханская область	6271	Хабаровский край	10182
Нижегородская область	6488	г. Москва	10965
Ставропольский край	6543	Сахалинская область	11083
Калужская область	6682	Республика Саха (Якутия)	11923
Тульская область	6740	Камчатский край	14384
г. Санкт-Петербург	7072	Чукотский авт. Округ	14766
Пермский край	7361	Ненецкий авт. округ	15517
Забайкальский край	7670		



- **Временные данные** отражают динамику изменения переменных, характеризующих объект, на некотором промежутке времени. В зависимости от способа измерения значений признака временные данные делятся на **моментные и интервальные**.
- **Моментные временные данные** представляют собой измерения (наблюдения) признака, сделанные в определенные моменты времени.


Примеры моментных временных данных

К таким данным относятся:

- температура воздуха в некотором городе России, измеренная в *определенное время* каждый день в течение месяца (года и т.д.);
- величина прожиточного минимума в некотором регионе РФ на *определенную дату* в течение нескольких лет.

Пример

Федеральный долг США на конец года за 1977—2014 гг. (в млн долл. США).
Данные представлены в виде столбиковой диаграммы



Интервальные временные данные характеризуют объект наблюдения за некоторый интервал времени. В отличие от моментных они измеряются не в какой-то момент времени, а в течение некоторого временного промежутка — недели, месяца, года и т.д.

Примеры интервальных временных данных


К таким данным относятся:

- сводки ГИБДД по количеству ДТП, произошедших в Москве за день, с 1 по 30 марта 2015 г.;
- годовой объем экспорта (импорта) России по годам за последние 20 лет;
- динамика ежегодных данных о количестве преступлений, совершенных в Российской Федерации за год, за последние 10 лет;
- число браков и разводов, зарегистрированных в Центральном федеральном округе по кварталам, за последние 10 лет.

Пример

Динамика числа родившихся (без мертворожденных) в Российской Федерации в течение года за 1990—2014 гг. (за 2014 г. — с учетом Крымского федерального округа). Данные представлены в табличной форме и в виде столбиковой диаграммы

Год	Количество родившихся за год, человек	Год	Количество родившихся за год, человек	Год	Количество родившихся за год, человек
1990	1 988 858	1999	1 214 689	2008	1 713 947
1991	1 794 626	2000	1 266 800	2009	1 761 687
1992	1 587 644	2001	1 311 604	2010	1 788 948
1993	1 378 983	2002	1 396 967	2011	1 796 629
1994	1 408 159	2003	1 477 301	2012	1 902 084
1995	1 363 806	2004	1 502 477	2013	1 895 822
1996	1 304 638	2005	1 457 376	2014	1 942 683
1997	1 259 943	2006	1 479 637		
1998	1 283 292	2007	1 610 122		



Пространственно-временные данные — значения переменных, относящихся к сходным объектам за несколько моментов времени. Они могут быть также как моментными, так и интервальными.


Примеры пространственно-временных данных

К таким данным относятся:

- сводки ГИБДД по количеству ДТП, произошедших в крупнейших российских городах за день, с учетом их видов, с 1 по 30 мая 2014 г.;
- динамика ежегодных данных о количестве преступлений по их видам, совершенных в азиатских странах, за последние 10 лет;
- число браков и разводов, зарегистрированных в федеральных округах Российской Федерации за последние 10 лет, по кварталам.

Пример

Данные Всемирной организации здравоохранения о среднем количестве детей у женщин некоторых стран мира за 1990 – 2013 гг. Данные представлены в табличной форме и в виде столбиковой диаграммы (*MS Excel*) по пяти объектам (четыре страны и весь мир в целом) по одному показателю — среднее число детей у женщин в динамике за три года.



1.4. Классификация данных по типу шкалы измерения признака

В зависимости от шкалы измерения различают **числовые** (количественные) и **категориальные** (нечисловые, качественные) **данные**.

Числовые (*numerical*) (количественные (*quantitative*)) данные – это показатели, принимающие числовые значения, которые получаются путем некоторых измерений или подсчетов.

С точки зрения шкал измерений количественные данные считают измеренными в **интервальной шкале**, которая применяется для отображения величины различия между характеристиками элементов.

Интервальная (количественная) шкала показывает, на сколько одно значение больше другого в принятых единицах измерения (например, шкала температур, времени, количества объектов). Интервальная шкала может иметь произвольные начало отсчета и масштаб. Множество допустимых преобразований данной шкалы составляют все линейные преобразования.

Основным свойством шкалы интервалов является сохранение отношения длин интервалов. Частными случаями шкалы интервалов являются **шкала отношений** (нулевое начало отсчета) и **шкала разностей** (произвольное начало отсчета и единичный масштаб), а также **абсолютная шкала** (нулевое начало отсчета и единичный масштаб отсчета).

Количественные шкалы допускают все арифметические действия над результатами измерения (суммирование, вычитание, умножение, деление).

В случае если данные получены путем измерений и они **могут принимать** абсолютно любые значения из некоторого промежутка или всей числовой оси, их называют **непрерывными** (*continuous*). Если данные образуют конечное или счетное множество и принимают только некоторые изолированные значения на числовой оси, между которыми значений быть не может, то такие признаки называют **дискретными** (*discrete*).

Примеры количественных дискретных данных

К таким данным относятся:

- число больных, поступающих в больницы г. Якутска ежедневно;
- количество страховых компаний в Российской Федерации, лишившихся лицензии, ежегодно;
- число беженцев и вынужденных переселенцев, зарегистрированных Федеральной миграционной службой РФ, за 2013 г.

Пример

Рейтинг уровня автомобилизации регионов России по количеству автомобилей на 1000 человек на 2012 г. Данные представлены в табличной форме, и в виде столбиковой диаграммы (численность населения по основной оси) и линейного графика (число автомобилей). Две переменные – количество автомобилей в регионе и население региона – дискретные количественные. Для наглядности на графике в виде линейного графика по вспомогательной оси (с другой шкалой) представлена переменная, рассчитанная как их отношение — число автомобилей на тысячу жителей (которая является непрерывной).

№ п/ п	Регион	Численность населения (оценка на конец года), человек	Число собственных легковых автомобилей в регионе на конец года, шт.	Число автомобилей на 1000 чело- век насе- ления, шт.
1	Чукотский автономный округ	50 668	3618	71,4
2	Чеченская Республика	133 5603	153 327	114,8
3	Брянская область	2 42 500	172 004	120,2
4	Курская область	1		
5	Белгородская область	1		
6	Калужская область	1		
7	Воронежская область	2		
8	Санкт-Петербург	5		
9	Москва	12		
10	Московская область	7		
11	Рязанская область	1		
12	Приморский край	1		
13	Камчатский край			



В Якутске в 2016 г.
228 автомобилей на
1000 человек.

Примеры количественных непрерывных данных


К таким данным относятся:

- рост, вес, давление крови и другие измеряемые физиологические показатели человека;
- урожайность сельскохозяйственных культур фермерских хозяйств РФ;
- дальность полета выпускаемого из орудия снаряда.
- динамика учетных цен на золото в России за последние 20 лет;

Пример

Рэнкинг банков России (топ-10) по чистым активам на 01.07.2015. Для представления данных по непрерывной количественной переменной «Чистые активы» использованы табличная форма и столбиковая диаграмма (*MS Excel*).

Банк	Чистые активы, млн руб.
ОАО «Сбербанк России»	20 552 763,1
ОАО «Банк ВТБ»	7 800 148,5
АО «Банк ГПБ»	4 509 806,1
ПАО Банк «ФК Открытие»	2 718 209,6
ПАО «ВТБ 24»	2 664 446,8
ОАО «Россельхозбанк»	2 288 207,5
АО «Альфа-банк»	20 000 000,00
ОАО «Банк Москвы»	
АО «Банк НКЦ»	
АО «ЮниКредит Банк»	15 000 000,00



Другую группу, существенно отличающуюся от количественных данных, составляют нечисловые – **категориальные (categorical)** или **качественные (qualitative)** данные. В этом случае объект может принадлежать только к одной из множества категорий (классов). Особенно часто это имеет место при создании и обработке анкет, опросников, рейтингов и т.д.

Даже если обозначить эти категории числами (например, перекодировать: 0 – женский, 1 – мужской пол), то с такими данными все равно нельзя работать как с числовыми, а можно только как с категориальными.

В зависимости от того, можно ли эти категории упорядочивать, различают признаки, измеренные в **номинальной** или **порядковой шкале**. В соответствии с этим данные разделяют на **номинальные (nominal)** и **порядковые (ordinal)**.

Шкала наименований (номинальная, или классификационная шкала).

Данные по этой шкале определяются в терминах категорий, которые нельзя содержательно упорядочить (профессия; регион страны; город; номер студенческой группы; банк, в котором имеется вклад). Номинальная шкала используется **для описания принадлежности элементов к определенным классам**. Всем элементам одного и того же класса присваивается одно и то же текстовое значение или число, а элементам разных классов – разные значения или числа. Нет оснований полагать, что одна категория лучше (или хуже), чем другая, поэтому при обработке таких данных применяются только операции сравнения: <<**равно**>> и <<**не равно**>>.

Примеры категориальных номинальных данных

К таким данным относятся:

- группа крови человека (0, А, В, АВ);
- семейное положение (холост/не замужем, женат/замужем);
- банк России («Сбербанк», ВТБ, «Газпромбанк» и т.д.);
- федеральные округа РФ (Центральный, Южный, и т.д.)

Другой тип категориальных переменных – **порядковые (ординальные)** – отличается тем, что данные измеряются в *порядковой шкале*. Порядковые шкалы используются для упорядочения элементов по одному или нескольким признакам. Порядковая шкала отражает лишь порядок следования элементов и не дает возможности сказать, на сколько или во сколько раз один элемент предпочтительнее другого. Иными словами, в этой шкале нельзя определить меру степени предпочтительности. Для сравнения таких данных допускаются уже не только операции **равно** и **не равно**, но и **больше-меньше** (без определения, на сколько).

Примеры категориальных порядковых данных

К таким данным относятся:

- должность, занимаемая сотрудником в научной лаборатории (младший научный сотрудник, научный сотрудник, старший научный сотрудник и т.д.);
- воинские звания в Российской армии (лейтенант, капитан и т.д.).
- ответы на вопросы анкеты, содержащей следующие варианты ответов: да; больше да, чем нет; больше нет, чем да; нет;

1.5. Классификация данных по способу их получения

По способу получения данные делятся на **первичные** – если информация собиралась специально для данного анализа и **вторичные** – если используется информация из других источников, собранная другими людьми и для других целей.

Первичные данные могут быть собраны самостоятельно или другими людьми по заказу, главное отличие – их сбор планируется и осуществляется в соответствии с задачами конкретного исследования. Поэтому они, конечно, обладают рядом преимуществ, прежде всего поскольку в этом случае достигается максимум соответствия собранных данных требованиям и целям проводимого анализа. Но, к сожалению, часто такие исследования могут быть недоступны или слишком дороги.

Примеры первичных данных

В качестве таких данных могут выступать:

- данные о стоимости туристических путевок, полученные путем изучения сайтов и телефонного опроса туристических агентств и компаний;
- данные о потребительском спросе на категорию продукции, планируемой к выпуску, заказанные профессиональному маркетинговому агентству;
- данные, собранные отделом контроля качества собственной компании, о характеристиках производимой продукции.

Более распространенным вариантом является **использование вторичных данных** — уже собранных специализированными фирмами или просто другими исследователями. Вторичные данные обладают своими преимуществами — они, как правило, гораздо дешевле или вообще бесплатны, могут быть велики по объему, зачастую собираются при помощи специальной труднодоступной аппаратуры и профессиональными в соответствующей области исследователями.

Примеры вторичных данных

В качестве таких данных могут выступать:

- статистические данные Федеральной службы государственной статистики о социально-экономическом положении субъектов РФ в 1990 – 2014 гг. (www.gks.ru);
- динамика курсов доллара США и евро к рублю и показатели биржевых торгов за период с 20.06.2005 по 01.01.2015 по данным Центрального банка Российской Федерации (www.cbr.ru);
- статистические данные по итогам деятельности страховщиков – страховые премии и выплаты, количество заключенных договоров и т.д. за 2005—2015 гг. по данным Службы Банка России по финансовым рынкам (www.fcsm.ru);
- инвестиционные рейтинги регионов России за 2005—2015 гг. по оценкам рейтингового агентства «Эксперт РА» (www.raexpert.ru);