

1.2. Анализ одномерных категориальных данных

1.2.1. Номинальные данные

Измерение в номинальной (классификационной) шкале означает определение принадлежности объекта к тому или иному классу.

Например: пол, профессия, страна и т.д. В этой шкале, таким образом, можно лишь посчитать количество объектов в классах — **частоту** m_i и **относительную частоту** (частость) m_i/n .


Таблицы частот, или, как еще их называют, **одновходовые таблицы**, представляют собой простейший метод анализа категориальных переменных. Часто таблица частот дополняется **накопленными** (**кумулятивными**) частотами, показывающими суммарное число объектов во всех классах до рассматриваемого, включая его, и соответствующими **относительными частотами** (**частостями**) m_i/n или m_{iH}/n .

Таблица 1.1

Типичная таблица частот категориальной переменной

Категория (класс) Переменной	Частота m_i	Накопленная частота m_{iH}	Относительная частота m_i/n	Относительная накопленная частота m_{iH}/n
Класс 1	3	3	0,086	0,086
Класс 2	6	9	0,171	0,257
Класс 3	7	16	0,200	$16/35 \approx 0,457$
Класс 4	11	27	0,314	0,771
Класс 5	5	32	0,143	0,914
Класс 6	2	34	0,057	0,971
Класс 7	1	35	0,029	1,000


Как правило, номинальные данные графически иллюстрируются при помощи гистограмм или круговых диаграмм.



Гистограмма отражает *распределение частот встречаемости* каждого значения признака, а не значения самого признака для различных объектов и *позволяет указать распределение объектов по классам, самые редко и часто встречающиеся значения.*

Гистограмма была введена в статистику известным английским математиком, основателем математической статистики **Карлом Пирсоном** (Karl Pearson) в 1895 г.

Круговые диаграммы особенно хорошо подходят для визуализации **категориальных данных**. Пример круговой диаграммы для данных таблицы 1:



Вид типичной круговой диаграммы для категориальных данных

Пример. Для журнала убытков договоров страхования автокаско (табл. 1.2) проанализируем переменную «**Причина страхового случая**» и построим частотную таблицу встречаемости каждой причины и круговую диаграмму, иллюстрирующую полученные результаты.

Таблица 1.2

Исходная таблица данных (фрагмент)

Номер договора	Причина страхового случая
1	Ущерб
2	ПДТЛ
3	ДТП
4	Не указан
5	ДТП
6	ПДТЛ
7	Стекло
8	Ущерб
9	ДТП
10	ДТП
11	ПДТЛ
12	ДТП
13	Эвакуация ТС
14	ДТП
15	ДТП
...	...
10 858	Падение предмета на а/м
10 859	ДТП

Переменная «Причины страхового случая» - категориальная, номинальная (нет оснований считать какую-то причину более важной, чем другая). Для анализа таких данных строят частотные таблицы и графики, например круговые диаграммы.

Таблица 1.3

Мастер **Сводных таблиц MS Excel** позволяет быстро получить таблицу, в которой каждая из категорий исследуемой переменной указана вместе с частотой встречаемости (табл. 1.3).

Таблица частот

Причина страхового случая	Частота m_i
Авария коммунальных систем	4
Гражданская ответственность	3
Дорожно-транспортное происшествие (ДТП)	6198
Не указан	329
Падение льда	18
Падение предмета на а/м	67
Падение снега	2
Противоправные действия третьих лиц (ПДТЛ)	1544
Пожар	29
Попытка угона	4
Стекло	1878
Стихийное бедствие	5
Угон	108
Ущерб	667
Эвакуация ТС	2
Общий итог	10 859

Круговая диаграмма (рис. 1.4) позволяет визуально оценить, насколько часто (в %) в исследуемом портфеле встречаются указанные причины страхового случая.



Рис. 1.4. Круговая диаграмма к примеру – распределение числа страховых характеристик случаев в портфеле автокаско по их причинам, %

Для описания категориальных переменных не используются никакие числовые характеристики, т.к. они не принимают числовых значений измеренных в интервальной шкале.

Единственной полезной характеристикой является **мода**.


Мода – наиболее часто встречающееся значение переменной. Мода может быть не единственной, если **два** или **несколько** значений переменной обладают одинаковой максимальной частотой. В этом случае распределения называются **бимодальными** или **полимодальными**.

Модой переменной **Причина страхового случая** из примера является категория **ДТП**, так как ей принадлежит **6198** договоров — **56%** всего страхового портфеля.

Еще одним способом графического отображения и анализа категориальных номинальных данных является так называемая **диаграмма Парето**.

Диаграмма Парето – это гистограмма, изображающая *частоты встречаемости признака в убывающем порядке*, на которую накладывается точно-линейный график из *накопленных частот* (или процентов, долей), отражающий накопленную частоту (или частоту) значений признака.

Диаграмма Парето используется для того, чтобы отделить несколько существенных факторов от множества несущественных, и поэтому называется еще **Правило 80–20** – 80% результата часто обусловлены действием 20% всех вызывающих их факторов.



■ Гистограмма распределения числа страховых случаев по причинам

—●— Диаграмма Парето (накопленная частота)

В нашем случае диаграмма Парето также позволила выделить самые главные причины страховых случаев. Всего две причины вызывают около 74,4% всех страховых случаев – ДТП и повреждения стеклянных элементов машин (фар, стекол, зеркал) (Стекло).

С учетом третьей причины — противоправных действий третьих лиц (ПДТЛ) — доля договоров, вызванных этими причинами, достигает практически 88,6%.

1.2.2. Порядковые данные

Измерение в *порядковой (ординальной)* шкале, помимо определения класса принадлежности позволяет упорядочить наблюдения, сравнив их между собой в каком-то смысле – лучше/хуже, больше/меньше, *не определяя, насколько лучше/хуже или больше/меньше.* Порядковые экспериментальные данные, даже если они перекодированы в цифры, *нельзя выполнять над ними арифметические операции.*

Проводя статистический анализ порядковых данных, кроме подсчета частот встречаемости категорий и формирования соответствующих таблиц частот, нахождения моды, можно вычислить **ранг объекта** и изобразить исходные данные с их значениями в виде **столбиковой диаграммы**, если их число не очень велико. Порядковую шкалу также называют **ранговой**, а место объекта в последовательности, которую она собой представляет, – **рангом** объекта.

Пример

Проанализируем ведомость с результатами экзамена 32 студентов, построим частотную таблицу встречаемости каждого балла за экзамен, столбиковую диаграмму и гистограмму, иллюстрирующую полученные результаты.

Балл за экзамен — порядковая переменная, принимающая значения от 0 до 10, каждое из которых говорит о более высоких показанных на экзамене знаниях.

Исходная таблица

Таблица 1.4



№ п/п	Балл за экзамен	№ п/п	Балл за экзамен
1	6	17	5
2	4	18	8
3	9	19	7
4	5	20	7
5	7	21	6
6	5	22	5
7	9	23	4
8	10	24	6
9	1	25	6
10	8	26	5
11	8	27	6
12	4	28	6
13	3	29	7
14	7	30	2
15	3	31	4
16	7	32	6

Исходную таблицу преобразуем в частотную, подсчитав частоту каждого балла.

Таблица 1.5

Таблица частот баллов за экзамен

Балл на экзамене	Частота m_i	Балл на экзамене	Частота m_i
0	0	6	7
1	1	7	6
2	1	8	3
3	2	9	2
4	4	10	1
5	5		




Построим гистограмму переменной **Балл на экзамене** (выше).

Для сравнения построим график исходных значений — столбиковую диаграмму (слева).

Мода исследуемой переменной – оценка 6 баллов. Именно этот балл получили наибольшее число студентов – семь человек.

Сразу видны различия этих двух видов графиков: **столбиковая диаграмма** показывает исходный массив без какого бы то ни было структурирования – значения переменной для каждого объекта, а **гистограмма “Балл на экзамене”** – результаты статистического анализа данных, подсчета частот встречаемости каждого значения. Как очевидно, **гистограмма** гораздо лучше характеризует исследуемую совокупность, **показывая распределение частот оценок**, выявляя баллы с наибольшей частотой (**моду**) и наименее встречающиеся баллы, позволяет проанализировать данные. Но **столбиковая диаграмма** также выполняет свою задачу – отражает индивидуальность объектов, ведь студентам, к примеру, интересны их собственные оценки, а не распределение баллов по группе, что может их заинтересовать только в дополнение к информации о своих результатах.

Можно построить имеющую большую наглядность столбиковую диаграмму для ранжированных от минимальной к максимальной всех оценок студентов группы.



Новую порядковую переменную — «оценка за экзамен по 4-балльной текстовой шкале» — построим согласно условию задачи, присвоив ей значения «отлично», если балл составляет 8, 9, 10, «хорошо» — при 6 или 7 баллах, «удовлетворительно» — при 4 или 5 баллах и «неудовлетворительно», если набрано меньше 4 баллов.

Для облегчения этой задачи удобно использовать в MS Excel функцию ЕСЛИ (=ЕСЛИ(B2>=8; «отлично»; ЕСЛИ(B2>=6; «хорошо»; ЕСЛИ(B2>=4; «удовлетворительно»; «неудовлетворительно»))) (в ячейке B2 находится исходный балл первого в списке студента). Значения полученной порядковой переменной, принимающей четыре значения, для каждого студента группы представим в виде столбиковой диаграммы (рис. 1.9).

Построим таблицу частот и относительных частот новых баллов, сгруппировав данные (табл. 1.6), а затем на ее основе — круговую диаграмму (рис. 1.10).





Рис. 1.9. Столбиковая диаграмма полученных за экзамен оценок по 4-х бальной шкале

Таблица частот по 4-бальной шкале

Таблица 1.6

Балл на экзамене	Частота m_i	Относительная частота, %
«Отлично»	6	19
«Хорошо»	13	41
«Удовлетворительно»	9	28
«Неудовлетворительно»	4	12

Модой построенной переменной является оценка «хорошо», которой соответствует максимальная частота – 13 человек, или 41% всех объектов наблюдений.



Количественные переменные можно превратить в категориальные, т.е. их категоризовать (категорировать). Такие переменные часто называют категоризованными (категорированными). Например, непрерывная переменная «вес человека в килограммах» может быть превращена в порядковую переменную «вес человека» с градациями: *недостаточный, нормальный, избыточный*; для обозначения размеров одежды во многих странах используют следующую порядковую шкалу: S, M, L, XL, XXI, и т.д.

Переменные с двумя категориями (есть свойство — нет свойства; купил — не купил и т.д.) обычно кодируют цифрами 0 и 1 и называют дихотомическими или бинарными. Особенно широкое применение они имеют в экономических, медицинских и социологических исследованиях, в которых большинство переменных, интересующих специалистов, измеряется в качественных шкалах. При этом дихотомические данные зачастую являются более адекватными, чем результаты измерений по методикам, использующим большее число категорий. Например, психологические тесты типа MMPI (Minnesota Multiphasic Personality Inventory — личностный опросник, разработанный в конце 1930-х в Университете Миннесоты. Наиболее изученная и одна из самых популярных психодиагностических методик) используют только дихотомические данные.

Упражнение. По данным обследования группы крови студентов, представленным в таблице, определите шкалу измерения признака, постройте частотную таблицу и дайте графическое представление в виде круговой диаграммы.

№ п/п	Группа крови	№ п/п	Группа крови	№ п/п	Группа крови	№ п/п	Группа крови	№ п/п	Группа крови
1	I	6	II	11	II	16	I	21	II
2	II	7	I	12	II	17	I	22	III
3	I	8	I	13	IV	18	III	23	II
4	III	9	II	14	I	19	II	24	III
5	IV	10	III	15	II	20	I	25	I

1.3. Анализ одномерных количественных данных

Так как практические исследования зачастую связаны с достаточно большими массивами данных, одной из первых у исследователя возникает задача их **сгруппировать**, изучить их внутреннюю структуру, представить в более компактном и удобном виде, дающем лучшую визуализацию таких данных.

1.3.1. Группировка дискретных количественных данных

Пусть имеются данные n наблюдений $x_1, x_2, \dots, x_n$, каждое из которых характеризует один количественный признак X . Если число наблюдений (n) достаточно велико (по крайней мере $n \geq 50$), то их предварительно ранжируют и подвергают группировке.

Вариационный ряд — значения n независимых наблюдений $x_1, x_2, \dots, x_n$ количественного признака X , расположенные в порядке возрастания (неубывания) значений: $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(i)} \leq x_{(i+1)} \leq \dots \leq x_{(n)}$. Элемент $x_{(i)}$ называется **i -й порядковой статистикой**, **главные порядковые статистики** — наименьшее значение $x_{(1)} = \min\{x_{(i)}\}$ и наибольшее значение $x_{(n)} = \max\{x_{(i)}\}$.

Разность наибольшего и наименьшего значений признака называется **размахом** вариационного ряда:

$$R = x_{(n)} - x_{(1)} = x_{\max} - x_{\min}.$$

Размах служит самостоятельной характеристикой **разброса значений** изучаемого признака.

С целью улучшения представления эмпирических данных при большом числе наблюдений их группируют, получая **сгруппированный вариационный ряд**.

Для группировки *дискретных* количественных данных подсчитывают частоту встречаемости **m_i** каждого признака **x_i** . При достаточно большом числе значений сгруппированный вариационный ряд может быть подвергнут дальнейшей группировке и **преобразован в интервальный**.

Сгруппированный дискретный вариационный ряд представляет собой k значений признака x_i , указанных вместе с соответствующими частотами m_i или **частотами** $w_i = m_i/n$ (эти частоты называют **эмпирическими**):

Значения признака x_i	$x_{(1)}$	$x_{(2)}$	...	$x_{(i)}$	...	$x_{(k)}$
Частоты m_i	m_1	m_2	...	m_i	...	m_k

Сгруппированный дискретный вариационный ряд графически представляют в виде **гистограммы** или **полигона**.

Полигон – графическое изображение сгруппированного дискретного вариационного ряда в виде ломаной, соединяющей точки, по оси абсцисс соответствующие всем возможным значениям признака, а по оси ординат – значениям частот m_i или относительных частот $w_i = m_i/n$.

Сгруппированный кумулятивный дискретный вариационный ряд представляет собой значения признака x_i , указанные вместе с соответствующими накопленными **частотами** m_{iH} или **частотами** $w_{iH} = m_{iH}/n$:

Значения признака x_i	$x_{(1)}$	$x_{(2)}$	...	$x_{(k)}$
Частоты m_{iH}	$m_{1H} = m_1$	$m_{2H} = m_1 + m_2$	...	$m_{kH} = n = \sum_{i=1}^n m_i$

Сгруппированный кумулятивный дискретный вариационный ряд графически представляют в виде **кумуляты**.

Кумулятивная кривая (кумулята), или **огива** – графическое изображение сгруппированного кумулятивного дискретного вариационного ряда в виде столбцов, при построении которого по оси абсцисс откладывают все возможные значения признака, а по оси ординат – *накопленные частоты* или *накопленные относительные частоты*, относящиеся к данному значению. **Кумулята показывает** количество (или долю) объектов совокупности, значения признака которых не превышают заданного.

Пример 1

По данным представленной таблицы результатов анализа числа промахов 30 случайно отобранных спортсменов, участвовавших в соревнованиях и сделавших по **10** выстрелов по движущейся мишени (табл. 1.7), требуется построить вариационный дискретный ряд и получить различные графические изображения ряда данных – гистограмму, полигон и кумуляту частот и относительных частот ряда распределения:

Таблица 1.7

5	1	3	4	5	6
1	3	4	6	8	1
4	6	3	3	2	2
2	6	3	3	7	2
0	0	4	1	2	4

Чтобы построить вариационный ряд, значения необходимо ранжировать в порядке неубывания:

**Вариационный ряд числа промахов 30
случайно отобранных спортсменов**

x_i	0	0	1	1	1	1	2	2	2	2	2	3	3	3	3
	3	3	4	4	4	4	4	5	5	6	6	6	6	7	8

По полученному *вариационному ряду* уже легко посчитать, сколько раз встречается каждое значение и построить сгруппированный ряд

Попаданий	0	1	2	3	4	5	6	7	8
m_i - частота	2	4	5	6	5	2	4	1	1

Сгруппированный дискретный вариационный ряд можно сразу из исходных данных с помощью функции **MS Excel ЧАСТОТА**.

Для этого после определения **возможных значений признака** нужно выделить область, состоящую из смежных ячеек, количество которых **на единицу больше** количества значений (в примере, ниже, выделена серым цветом), вызвать встроенную статистическую функцию **ЧАСТОТА**, **выделить массив данных** и **массив возможных значений признака** в соответствующих окнах функции, нажать комбинацию клавиш для работы с матрицами CTRL + SHIFT + ENTER (**Ок не нажимать**), после чего в выделенной (серой) области появятся частоты встречаемости значений в массиве данных:

Исходные данные					
5	1	3	4	5	6
1	3	4	6	8	1
4	6	3	3	2	2
2	6	3	3	7	2
0	0	4	1	2	4

Значения
0
1
2
3
4
5
6
7
8

Частоты
2
4
5
6
5
2
4
1
1
0

Аналогично можно построить сгруппированный вариационный ряд с помощью модуля *MS Excel* АНАЛИЗ ДАННЫХ – Гистограмма.

На основе полученных значений частот построим таблицу

Таблица 1.9

Значения признака x_i — число Промахов	0	1	2	3	4	5	6	7	8
Частота m_i — число спортсменов с таким числом промахов	2	4	5	6	5	2	4	1	1
Относительная частота $w_i = m_i / n$	2/30	4/30	5/30	6/30	5/30	2/30	4/30	1/30	1/30
Накопленная частота встречаемости — количество спортсме- нов с числом промахов не менее x_i — m_{iH}	2	6	11	17	22	24	28	29	30
Относительная накопленная частота $w_{iH} = m_{iH} / n$	2/30	6/30	11/30	17/30	22/30	24/30	28/30	29/30	1

Итак, полученный сгруппированный дискретный вариационный ряд и кумулятивный вариационный ряд частот и относительных частот числа промахов спортсмена представлены в табл. 1.9.

На основании данных табл. 1.9 мы можем построить все требуемые графики частот и относительных частот числа промахов — **гистограмму, полигон и кумуляту**.

По гистограмме частот и полигону распределения **легко определить моду** — число промахов с максимальной частотой: здесь это три промаха (встречается у шести спортсменов), и наиболее редкие значения признака — семь и восемь промахов встречаются всего лишь по одному разу.

Полигон строится по тем же точкам, что и гистограмма, просто имеем другой вид графика – не столбиковая диаграмма, а точечно-линейный график.




Рис. 1. Гистограмма частот числа промахов




Рис. 2. Полигон частот числа промахов

Для построения **кумуляты** используем **накопленные частоты**. График кумуляты позволяет найти число объектов, имеющих значения признака, не превышающие заданного.




Рис. 3. Кумулята частот числа промахов





Рис. 4. Гистограмма относительных частот числа промахов

Из рис.3 очевидно, что **24** спортсмена имеют число промахов, не превышающее **пяти** (от нуля до пяти промахов).

Графики относительных частот (Рис. 4.) показывают долю объектов с соответствующим значением переменной. Из рисунков очевидно, что **мода, равная трем** промахам, имеет относительную частоту встречаемости, равную 0,2. Это означает, что 20% (6 из 30) всех объектов совокупности (выбранных спортсменов) имеет ровно три промаха.

Для построения **кумуляты** накопленных относительных частот используем относительные **накопленные частоты**.



Кумулята показывает, какая доля w_{in} (какое число m_{in}) наблюдений исследуемой совокупности не превышает заданного значения. Например, из рисунка видно, что 57% участников имеют меньше 5 промахов.

Построим **кумуляту** накопленных относительных частот на
Питоне:



```
# -*- coding:cp1251 -*-
import platform
term_enc = 'utf-8' if platform.uname()[0] == 'Linux' else 'cp1251'
import matplotlib.pyplot as plt
plt.figure(figsize=(6,4))
x = [0, 1, 2, 3, 4, 5, 6, 7, 8]
y = [0.07, 0.20, 0.37, 0.57, 0.73, 0.80, 0.93, 0.97, 1.00]
labels = list(map(str, y))
plt.bar(x, y, linewidth = 0.8, width = 0.4)
plt.plot(x, y, color='red', marker='s', markersize=7)
plt.xlim(-0.5, 9)
plt.ylim(0, 1.2)
plt.xlabel('Число промахов $x_i$', fontsize = 12)
plt.ylabel('Накопленные \n относительные частоты', fontsize = 12)
plt.title('Кумулята \n накопленных относительных частот', fontsize = 14)
for i in range(9):
    plt.text(x[i] - 0.3, y[i] + 0.05, labels[i])

plt.tight_layout()
plt.show()
```

1.3.2. Построение интервального вариационного ряда для непрерывных количественных данных

При обработке **больших массивов информации**, что особенно актуально при проведении современных научных разработок, перед исследователем стоит серьезная задача правильной группировки исходных данных. Если данные имеют дискретный характер, то проблем, как мы видели, не возникает – необходимо просто подсчитать частоту m_i каждого признака x_i . Если же исследуемый признак имеет **непрерывный** характер, то выбор оптимального числа интервалов группировки признака является отнюдь не тривиальной задачей.

Для группировки непрерывных случайных величин весь вариационный **размах признака**


$$R = x_{(n)} - x_{(1)}$$

разбивают на некоторое количество интервалов k .


Сгруппированным интервальным (непрерывным) вариационным рядом называют ранжированные по значению признака интервалы ($a_i \leq x < b_i$), где $i = 1, 2, \dots, k$, указанные вместе с соответствующими частотами (m_i) числа наблюдений, попавших в i -й интервал, или относительными частотами (m_i/n):

Интервалы значений признака $a_i \div b_i$	$a_1 \div b_1$	$a_2 \div b_2$	...	$a_i \div b_i$	...	$a_k \div b_k$
Частота m_i	m_1	m_2	...	m_i	...	m_k

При этом гистограмму и кумуляту (огиву) для непрерывных данных строят с учетом того, что непрерывные данные сплошь заполняют область своих возможных значений, принимая любые значения.



Интервалы значений переменной



Интервалы значений переменной

Пример гистограммы (слева) и кумуляты (справа) интервального ряда

Интервалы *не должны пересекаться* и имеют, как правило, одинаковую ширину.

Построение интервального вариационного ряда начинают *с определения числа интервалов k* . И эта задача, пожалуй, является самой сложной, важной и неоднозначной в изучаемом вопросе.

Число интервалов не должно быть слишком малым, так как при этом гистограмма получается слишком сглаженной, теряет все особенности изменчивости исходных данных.

В то же время число интервалов не должно быть слишком велико — иначе мы не сможем оценить плотность распределения изучаемых данных по числовой оси: гистограмма получится недосглаженная, с незаполненными интервалами, неравномерная.


Еще в 1926 г. Герберт Стерджес (Herbert Sturges) предложил формулу для вычисления количества интервалов, на которые необходимо разбить исходное множество значений изучаемого признака. На чем основана формула Стерджеса?

Рассмотрим биномиальное распределение с вероятностью $p = 1/2$ и k значениями ($i = 0, 1, 2, \dots, k - 1$), вероятности которых равны согласно формуле Бернулли $\frac{C_{k-1}^i}{2^{k-1}}$. Стерджес предложил использовать биномиальные коэффициенты C_{k-1}^i – как частоты интервалов идеальной гистограммы для нормальных данных, так как форма полученной гистограммы выглядит как нормальная кривая при возрастании k . Тогда объем выборки наблюдений n равен сумме C_{k-1}^i , и, используя свойства биномиальных коэффициентов (или нормировку суммы всех вероятностей дискретной случайной величины), получаем:

$$n = \sum_{i=0}^{k-1} C_{k-1}^i$$

Таким образом, приблизительное число классов k , которое необходимо выбрать при группировке и построении гистограммы для n результатов измерений величины, полученных из нормально распределенной генеральной совокупности, определяется по правилу Стерджеса следующим образом:

$$k = 1 + \log_2 n \approx 1 + 3,322 \lg n.$$



Идеальная гистограмма Стерджеса для 10 интервалов

Ширина интервалов h , на которые необходимо разбить всю область возможных значений исследуемого признака по имеющимся наблюдениям $\{x_1, x_2, \dots, x_n\}$, определяется тогда следующим образом:

$$h = \frac{R}{1 + \log_2 n} = \frac{x_{\max} - x_{\min}}{1 + \log_2 n} \approx \frac{x_{\max} - x_{\min}}{1 + 3,322 \lg n}$$

где R — размах значений признака.

Итак, можем сформулировать этапы построения интервального вариационного ряда распределения для непрерывных количественных данных.

1. Определение среди имеющихся наблюдений минимального $x_{\min}$ и максимального $x_{\max}$ значений признака.

2. Определение размаха варьирования признака

$$R = x_{\max} - x_{\min}.$$

3. Определение ширины интервала, например, с помощью формулы Стерджеса.

4. Определение граничных значений интервалов ($a_i; b_i$).

Рекомендуется отступить влево от нижнего предела варьирования ($x_{\min}$), так как минимальное наблюдение данной совокупности может быть не минимально возможным значением признака. За **нижнюю границу** первого интервала обычно принимается величина $a_1 = x_{\min} - h/2$. Если оказывается, что $a_1 < 0$, хотя по смыслу рассматриваемая величина неотрицательная, то принимают $a_1 = 0$.

Верхняя граница первого интервала $b_1 = a_1 + h$. При определении границ следующих интервалов исходят из условий: $a_{i+1} = b_i$; $b_i = a_i + h$. Построение интервалов продолжается до тех пор, пока начало следующего по порядку интервала не будет равным или больше $x_{\max}$.

5. Группировка результатов наблюдения: при просмотре статистических данных значения признака разносятся по соответствующим интервалам. При этом, так как значения признака могут совпадать с границами интервалов, принято в каждый интервал включать варианты, большие, чем нижняя граница интервала, или равные ей и меньшие верхней границы, т.е. $a_i \leq x_i < b_i$. Общее количество значений признака, отнесенное к интервалу, определяет частоту этого интервала m_i .

Для группировки больших массивов можно использовать уже рассмотренные выше при изучении дискретных признаков функцию EXCEL ЧАСТОТА или АНАЛИЗ ДАННЫХ – гистограмма.

Если получаются интервалы с нулевыми частотами, рекомендуется увеличить ширину интервала h и заново построить интервалы.

Число k для небольших объёмов данных обычно берут следующими:

- 5 - 6 при $n \leq 50$;
- 6 - 8 при $50 < n \leq 100$;
- 8 - 10 при $100 < n \leq 200$.

Считается, что формула Стерджеса позволяет строить удовлетворительные гистограммы при числе измерений менее 200. Для современных огромных массивов информации, например порядка $10^4 - 10^9$ наблюдений, может приводить к слишком сглаженным гистограммам.