

1.3.3. Основные числовые характеристики одномерных количественных данных

Для того чтобы изучать какие-то количественные переменные и сравнивать их между собой, необходимо уметь рассчитывать основные числовые характеристики признаков.

Для проведения дальнейших вычислений, как правило, интервальный вариационный ряд заменяется дискретной. С этой целью все значения признака в пределах каждого интервала приравниваются к его среднему значению $x_i = \frac{a_i + b_i}{2}$.

Характеристики центра группирования данных

Средние величины. Средние представляют собой обобщающие показатели, характеризующие центр группирования данных. Обычно рассматривают средние: *арифметическую, гармоническую и геометрическую.*

Вид средней выбирается согласно следующему свойству: значение определяющей функции $\phi(x_1, x_2, \dots, x_n)$ не изменится, если исходные данные заменить средней.

Средняя арифметическая — одна из основных числовых статистических характеристик, отражающая среднее от значений имеющихся наблюдений.

Фонд оплаты труда n работников $x_1, x_2, \dots, x_n$ можно представить как $\sum_{i=1}^n x_i$ и как $\bar{x} \cdot n$, где $\bar{x}$ — средняя заработная плата n работников. Тогда

$$\sum_{i=1}^n x_i = \sum_{i=1}^n \bar{x} = n \cdot \bar{x}$$

и получаем *среднюю арифметическую*

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Если данные сгруппированы, причем заработную плату x_i , получают m_i работников, где $i = 1, 2, \dots, k$ и $n = \sum_{i=1}^k m_i$, т.е. имеем

x_1	x_1	...	x_k
m_1	m_2	...	m_k

То получится **средняя арифметическая** взвешенная:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k x_i m_i.$$

Средняя гармоническая

В единицу времени n рабочих изготавливают соответственно $x_1, x_2, \dots, x_n$ изделий. Требуется определить среднюю производительность труда n рабочих.

Суммарное время изготовления n изделий n рабочими равно

$$\sum_{i=1}^n \frac{1}{x_i} = \sum_{i=1}^n \frac{1}{\bar{x}_{\text{гарм}}} = \frac{n}{\bar{x}_{\text{гарм}}}.$$

Определяющее правило: суммарное время изготовления рабочими n изделий не изменится, если все x_i заменить на $\bar{x}$.

Отсюда получается ***средняя гармоническая***

$$\bar{x}_{\text{гарм}} = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}$$

Пусть за время пути автомобиль m_i километров проехал со скоростью x_i , где $i=1,2,\dots,k$, $\sum_{i=1}^k m_i = n$. Требуется определить среднюю скорость автомобиля за все время пути.

Определяющее правило: общее время в пути не изменится, если фактическую скорость x_i заменить на среднюю.

Из определяющей функции следует, что суммарное время равно

$$\sum_{i=1}^k \frac{m_i}{x_i} = \sum_{i=1}^k \frac{m_i}{\bar{x}_{\text{гарм}}} = \frac{\sum_{i=1}^k m_i}{\bar{x}_{\text{гарм}}} = \frac{n}{\bar{x}_{\text{гарм}}}.$$

Тогда получается **средняя гармоническая взвешенная**:

$$\bar{x}_{\text{гарм}} = \frac{n}{\sum_{i=1}^k \frac{m_i}{x_i}}$$

Средняя геометрическая

Пусть $x_1, x_2, \dots, x_n$ — темпы роста объема производства за n лет. Требуется определить средний темп роста.

Определяющее правило: произведение темпов роста не изменится, если все $x_1, x_2, \dots, x_n$ заменить на средний темп роста $x_{\text{геом}}$, т.е. выполняется условие $\prod_{i=1}^n x_i = \prod_{i=1}^n \bar{x}_{\text{геом}}$, тогда имеет место **средняя геометрическая**

$$\bar{x}_{\text{геом}} = \sqrt[n]{x_1 \cdot x_2 \cdot \dots \cdot x_n} = \sqrt[n]{\prod_{i=1}^n x_i}.$$

Если данные сгруппированы и x_i — i -е значение признака наблюдалось m_i раз, где $i=1, 2, \dots, k$, причем $\sum_{i=1}^k m_i = n$, получается **средняя геометрическая взвешенная**:

$$\bar{x}_{\text{геом}} = \sqrt[n]{\prod_{i=1}^k x_i^{m_i}}.$$

Средние геометрические используют часто при анализе временных данных.

Пример. На основе интервального вариационного ряда объемов производства предприятий легкой промышленности, представленного в таблице, требуется вычислить среднюю арифметическую этих объемов.

Объем производства, усл. ед.	102-104	104-106	106-108	108-110	110-112
Среднее значение	103	105	107	109	111
Количество предприятий	7	14	13	9	7

Средняя арифметическая для сгруппированных данных – интервального ряда вычисляется по формуле:

$$\begin{aligned}\bar{x} &= \frac{1}{n} \sum_{i=1}^n x_i m_i = \frac{103 \cdot 7 + 105 \cdot 14 + 107 \cdot 13 + 109 \cdot 9 + 111 \cdot 7}{50} \\ &= \frac{5340}{50} \text{ (усл. ед.)}.\end{aligned}$$

Другие характеристики центра группирования

Медиана – значение признака, приходящего на середину вариационного ряда наблюдений.

Для не сгруппированных данных:

- если число наблюдений нечетное, $n=2p+1$, где $p=1,2,\dots$, то $Me=x_{Me}=x_{(p+1)}$.
- если число наблюдений четное, $n=2p$, то $Me=x_{Me}=(x_{(p)}+x_{(p+1)})/2$.

Например, при $n=5$ имеем $x_{(1)} \leq x_{(2)} \leq x_{(3)} \leq x_{(4)} \leq x_{(5)}$ и $Me=x_{Me}=x_{(3)}$, при $n=6$ имеем $Me=x_{Me}=(x_{(3)}+x_{(4)})/2$.

Для **интервального вариационного ряда медианным называют** первый интервал $[a_{Me}; b_{Me})$, для которого накопленная частота впервые превышает половину объёма наблюдений (или равна ей), т.е. $m_{Me}^{(H)} \geq \frac{n}{2}$, а $m_{Me-1}^{(H)} < \frac{n}{2}$, где

$$m_1^{(H)}=m_1, m_2^{(H)}=m_1 + m_2, \dots, m_l^{(H)}=m_{l-1} + m_l, \dots, m_k^{(H)} = n.$$

Медиана для интервального вариационного ряда **вычисляется по формуле**

$$Me = x_{Me} = a_{Me} + h \cdot \frac{\frac{n}{2} - m_{Me-1}^{(H)}}{m_{Me}}.$$

где a_{Me} — нижняя граница медианного интервала;

$m_{Me-1}^{(H)}$ — накопленная частота интервала, предшествующего медианному; m_{Me} — частота медианного интервала; $h=(b_l - a_l)$ — ширина интервала группирования.

Свойство медианы: сумма абсолютных отклонений признака от Me меньше, чем от любой другой величины:

$$\sum_{i=1}^n |x_i - x_{Me}| = \min.$$

Мода – наиболее часто встречаемое значение признака – для интервального сгруппированного вариационного одномодального ряда равна

$$Mo = x_{Mo} = a_{Mo} + h \cdot \frac{m_{Mo} - m_{Mo-1}}{2m_{Mo} - m_{Mo-1} - m_{Mo+1}},$$

где a_{Mo} – нижняя граница модального интервала (интервала с наибольшей частотой) (см. рис.):
 m_{Mo} – частота модального интервала; m_{Mo-1} – частота интервала, предшествующего модальному; m_{Mo+1} – частота интервала, следующего за модальным.




Рис. Модальный интервал (выделен штриховкой)

Показатели вариации и моменты распределения

Показатели вариации характеризуют **величину разброса наблюдаемых значений** $x_1, x_2, \dots, x_n$ относительно среднего значения.

Дисперсия (*variation*) – средняя арифметическая квадрата отклонения наблюдаемых значений x_i от средней арифметической $\bar{x}$:

$$S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2. \quad (1)$$

Если данные сгруппированы и x_i -е значение признака – наблюдалось m_i раз, где $i = 1, 2, \dots, k$, причем $\sum m_i = n$, то получим **взвешенную формулу дисперсии**

$$S^2 = \frac{1}{n} \sum_{i=1}^k (x_i - \bar{x})^2 m_i. \quad (2)$$

Рассмотрим свойства дисперсии.

1. Дисперсия постоянной величины равна нулю: $S_c^2 = 0$.

Пусть $c = \text{const}$ и $x_i = c$ для всех $i = 1, 2, \dots, n$, тогда, учитывая свойства средней арифметической и подставляя в формулу c вместо x_i , получим

$$S_c^2 = \frac{1}{n} \sum_{i=1}^n (c - c)^2 = 0.$$

2. Если ко всем x_i прибавить c , где $c = \text{const}$, то дисперсия не изменится.

Пусть $c = \text{const}$, тогда

$$S_{x+c}^2 = \frac{1}{n} \sum_{i=1}^n [(x_i + c) - (\bar{x} + c)]^2 = S_x^2.$$

3. Если все x_i умножить на c , $c = \text{const}$, то дисперсия увеличится c^2 раз.

Пусть $c = \text{const}$, тогда

$$S_{xc}^2 = \frac{1}{n} \sum_{i=1}^n (cx_i - c\bar{x})^2 = c^2 \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = c^2 S_x^2.$$

4. Пусть $y_i = cx_i + b$ для всех $i = 1, 2, \dots, n$ и $b, c = \text{const}$. Тогда

$$S_y^2 = \frac{1}{n} \sum_{i=1}^n [(cx_i + b) - (c\bar{x} + b)]^2 = c^2 \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = c^2 S_x^2.$$

Иногда в качестве оценки дисперсии используют ее несмещенную оценку – так называемую исправленную выборочную дисперсию:

$$\hat{S}_c^2 = \frac{n}{n-1} S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Из формул (1) и (2) следует, что *дисперсия имеет размерность равную квадрату размерности признака*. Таким образом, если признак x измеряется в рублях, то размерность дисперсии – [руб.²], что представлялся неудобным во многих задачах. Для этого была введена еще одна статистическая характеристика разброса, лишенная этого недостатка.

Среднее **квадратическое (стандартное) отклонение** (*standard deviation*) S , равное положительному корню из дисперсии S^2 , имеет ту же размерность, что и x .

Среднее квадратическое отклонение равно

$$S = \sqrt{S^2}$$

Размах вариации (*range*) равен разности между максимальным и минимальным значениями признака:

$$R = x_{max} - x_{min} = x_{(n)} - x_{(1)},$$

где $x_{max} = x_{(n)}$ – максимальное, а $x_{min} = x_{(1)}$ – минимальное значение признака.

Размах вариации и среднее квадратическое отклонение связаны примерным соотношением $R = (4 \div 6)S$.

Квартили (от лат. *quarta* – четверть) – это такие значения изучаемого признака, левее (нижний квартиль) или правее (верхний квартиль) которых **находится четверть всех наблюдений**.

Q_1 – это $(n+1)/4$ – ранжированное наблюдение – **первый квартиль (нижний)** значение вариационного ряда данных, левее которого находится четверть (25%) всех наблюдений;

Q_3 – это $3(n+1)/4$ – ранжированное наблюдение – **третий квартиль** (верхний) – значение вариационного ряда данных, правее которого **находится четверть (25%) всех наблюдений**.

Например, если $n = 15$, то

$$x_{(1)} \leq x_{(2)} \leq x_{(3)} \leq \mathbf{x_{(4)}} \leq x_{(5)} \leq x_{(6)} \leq x_{(7)} \leq \mathbf{x_{(8)}} \leq x_{(9)} \leq x_{(10)} \leq x_{(11)} \leq \mathbf{x_{(12)}} \leq x_{(13)} \leq x_{(14)} \leq x_{(15)}$$

Q_1
 $Q_2 = Me$
 Q_3

Имеем $Q_1 = x_{(n+1)/4} = x_{(4)}$, $Q_3 = x_{3(n+1)/4} = x_{12}$, левее и правее этих значений в ранжированном ряду находится по четверти всех наблюдений.

Второй квартиль Q_2 — это рассмотренная ранее медиана Me , левее и правее которой находится половина всех значений (в данном примере это восьмое значение в ранжированном ряду). Таким образом, три квартиля Q_1 , $Q_2 = Me$ и Q_3 делят всю совокупность изучаемого признака на четыре равные по количеству наблюдений части (см. рис.).

Интерквартильный размах (*interquartile range*) отражает среднюю половину (50%) данных – различия между первым и третьим квартилем (см. рис.):

$$IQR = Q_3 - Q_1.$$

Коэффициент вариации является единственным безразмерным показателем вариации:

$$V_S = \frac{S}{\bar{x}}$$

но чаще **используется** его представление в процентах:

$$V_S = \frac{S}{\bar{x}} 100\%$$

Пример

Было отобрано по 10 корпусов каждого вида, т.е. $n_1 = n_2 = 10$, у которых измерены диаметры корпусов. Сравним точность обработки диаметра корпусов двух видов.

Решение

По результатам измерения получено $\bar{x}_1 = 50$ мм; $S_1 = 1$ мм и $\bar{x}_2 = 500$ мм; $S_2 = 1$ мм. Отсюда коэффициенты вариации для корпусов двух видов равны

$$V_1 = \frac{1}{50} \cdot 100\% = 2\%; \quad V_2 = \frac{1}{500} \cdot 100\% = 0,2\%;$$

Таким образом, точность изготовления деталей второго вида значительно выше.

Гистограмма




Рис. Квартили и интервальный размах

Моменты распределения

Моментом k -го порядка называют среднюю арифметическую k -й степени отклонения наблюдаемых значений x_i ($i = 1, 2, \dots, n$) от постоянной c , т.е.

$$\mu_k = \frac{1}{n} \sum_{i=1}^n (x_i - c)^k.$$

При $c = 0$ имеем начальный момент k -го порядка:

$$\hat{\nu}_k = \frac{1}{n} \sum_{i=1}^n x_i^k.$$

При $k = 0$ имеем $\hat{\nu}_0 = 1$.

При $k = 1$ имеем $\hat{\nu}_1 = \bar{x}$, т.е. средняя арифметическая есть начальный момент первого порядка.

При $k = 2$ начальный момент второго порядка $\hat{\nu}_2 = \overline{x^2} = \frac{1}{n} \sum_{i=1}^n x_i^2$ есть средняя арифметическая квадрата значения признака.

Обычно рассматривают моменты до четвертого порядка включительно, т.е. $k = 0, 1, 2, 3, 4$.

При $c = \bar{x}$ имеем **центральные моменты k -го порядка**:

$$\mu_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k.$$

При $k = 0$ центральный момент нулевого порядка равен единице: $\mu_0 = 1$.

Центральный момент первого порядка ($k = 1$) всегда равен нулю: $\mu_1 = 0$.

В самом деле:

$$\mu_1 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}) = \frac{1}{n} \sum_{i=1}^n x_i - \frac{1}{n} n\bar{x} = 0.$$

Центральный момент второго порядка $k=2$ есть дисперсия:

$$\mu_2 = S^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Легко показать, что начальные и центральные моменты связаны соотношениями

$$\mu_2 = \hat{v}_2 - \hat{v}_1^2; \quad \mu_3 = \hat{v}_3 - 3\hat{v}_2\hat{v}_1 + 2\hat{v}_1^3$$


Центральные моменты третьего и четвертого порядков обычно используются не сами по себе, а для расчета **коэффициентов асимметрии** и **эксцесса**.

Коэффициент асимметрии характеризует степень асимметричности, скошенности распределения данных и находится по формуле


$$Ac = \frac{\mu_3}{S^3},$$

где $\mu_3 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3$ – центральный момент третьего порядка; S – среднее квадратическое отклонение.


Коэффициент асимметрии был впервые введен Карлом Пирсоном в 1895 г. Из формулы следует, что при $Ac > 0$ имеет место правосторонняя асимметрия (на графике более пологий спуск справа); при $Ac < 0$ – левосторонняя асимметрия (на графике более пологий спуск слева); при $Ac = 0$ – идеально симметричное распределение (рис.). Если $|Ac| > 0,5$, то асимметрия существенна.



а



б



в

Рис. Гистограмма симметричного распределения (а) и распределений с правосторонней (б) и левосторонней (в) асимметрией.

Коэффициент эксцесса – показатель, служащий мерой крутости (плосковершинности или островершинности) графика вариационного ряда в сравнении с кривой нормального распределения, определяемый по формуле

$$Ek = \frac{\mu_4}{S^4} - 3,$$

где $\mu_4 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4$ – центральный момент четвертого порядка; S – среднее квадратическое отклонение.

Если $Ek > 0$, то график ряда распределения является островершинным, если $Ek < 0$ – плосковершинным по сравнению с нормальным (у нормального распределения коэффициент эксцесса равен нулю).

Коэффициент эксцесса был впервые введен Карлом Пирсоном в 1905 г. Также он ввел термины островершинности, плосковершинности и *mesokurtic* (примерно такая же, как у нормальной кривой, вершина).




Рис. Сравнение кривых трёх распределений с различными коэффициентами эксцесса