

Министерство науки и высшего образования Российской Федерации
ФГАОУ «Северо-Восточный федеральный университет имени
М.К. Аммосова»
Институт математики и информатики
Кафедра «информационные технологии»

ОТЧЕТ

По лабораторной работе №1

На тему: Анализ одномерных количественных данных
по дисциплине: Анализ данных

Направление подготовки: 02.03.02 Фундаментальная информатика и
информационные технологии

Выполнил: студент 4 курса
группы Б-ФИИТ-23, ИМИ,
СВФУ

Скрябин Владислав
Витальевич

Проверил: доцент кафедры
ИТ ИМИ СВФУ

Павлов Никифор Никитич

г. Якутск, 2026

Оглавление

Цели и задачи работы	3
Ход работы	4
0. Импортировать данные в Excel	4
1. Определить среди имеющихся наблюдений минимальное и максимальное значения признака	4
2. Определить размах варьирования признака	4
3. Определить длины интервала по формуле Стерджеса	4
4. Определить граничные значения интервалов (a_i -- b_i)	5
5. Группировать результаты наблюдений	5
6. Построить интервальный вариационный ряд распределения объемов основных фондов 100 предприятий, млн руб.	5
7. Построить гистограмму частот	5
8. Построить гистограмму относительных частот	6
9. Построить полигон частот интервального ряда	6
10. Построить кумуляту накопленных относительных частот интервального ряда	7
11. Сделать анализ гистограмм	8
12. Вычислить основные числовые характеристики по исходным несгруппированным данным и по вариационному ряду	9
а) средние: арифметическая, гармоническая и геометрическая	9
б) медиана и мода	10
с) начальные и центральные моменты первого, второго, третьего и четвёртого порядков	11
d) дисперсия и среднее квадратическое отклонение	11
е) коэффициенты асимметрии и эксцесса	12
f) коэффициент вариации	12
13. При помощи полученных значений коэффициентов асимметрии и эксцесса проанализировать построенные гистограммы	13
Заключение	15

Цели и задачи работы

Цель работы: освоить основные приёмы статистической обработки одномерных количественных данных.

Задание. Построить интервальный вариационный ряд с использованием формулы Стерджеса и изобразить его графически в виде гистограммы, полигона и кумуляты частот и относительных частот ряда распределения.

Ход работы

0. Импортировать данные в Excel

5,56	5,27	5,02	5,47	5,27	5,37	5,47	5,47	5,33	5,11
5,33	5,47	5,33	5,33	5,47	5,05	5,33	5,85	5,68	5,11
5,54	5,43	5,64	5,21	5,68	5,43	5,79	5,47	5,21	5,47
5,43	5,43	5,47	5,27	5,68	5,43	5,47	5,79	5,47	5,54
5,43	5,43	5,61	5,47	5,27	5,54	5,61	5,54	5,64	5,54
5,64	5,43	5,33	5,11	5,33	5,33	5,33	5,54	5,64	5,64
5,4	5,68	5,43	5,54	5,43	5,37	5,37	5,21	5,64	5,64
5,71	5,47	5,21	5,33	5,43	5,33	5,43	5,27	5,21	5,54
5,79	5,58	5,27	5,33	5,4	5,43	5,54	5,54	5,54	5,81
5,39	5,47	5,47	5,27	5,58	5,43	5,43	5,33	5,61	5,54

Рис. 1 – Объём основных фондов 100 предприятий, млн руб.

1. Определить среди имеющихся наблюдений минимальное и максимальное значения признака

Минимальное и максимальное значения найдены функциями Excel:
 $\text{=МИН}(X) \Rightarrow x_{\min} = 5,02 \text{ млн руб.}; \quad \text{=МАКС}(X) \Rightarrow x_{\max} = 5,85 \text{ млн руб.}$

2. Определить размах варьирования признака

$$R = x_{\max} - x_{\min} = 5,85 - 5,02 = 0,83 \text{ млн руб.}$$

3. Определить длины интервала по формуле Стерджеса

Число интервалов по формуле Стерджеса

$$k = 1 + 3,322 \lg n = 1 + \log_2 n = 1 + \log_2 100 \approx 7,644$$

(в Excel: $\text{=1+LOG}(100;2)$). Длина интервала

$$h = \frac{R}{k} = \frac{0,83}{7,644} \approx 0,1086.$$

Округляя вверх до сотых, принимаем $h = 0,11 \text{ млн руб.}$; число интервалов округляем вверх до целого: $k = 8$.

4. Определить граничные значения интервалов (a_i – b_i)

Начало первого интервала принято равным $a_1 = 4,98$ (как в образце). Далее $b_i = a_i + h$, $a_{i+1} = b_i$. Конец последнего интервала $b_8 = 5,86 > x_{\max} = 5,85$, следовательно, все наблюдения попадают в построенные интервалы. Интервалы считаются полуоткрытыми $[a_i; b_i)$.

5. Группировать результаты наблюдений

Частоты m_i (число наблюдений в каждом интервале) найдены функцией =СЧЁТЕСЛИМН(Х; ">="&S3;Х; "<"&T3), формула протянута на все 8 интервалов. Накопленная частота $m_i^{\text{нак}} = m_{i-1}^{\text{нак}} + m_i$; относительная частота $w_i = m_i/n$ при $n = 100$; накопленная относительная частота $w_i^{\text{нак}} = m_i^{\text{нак}}/n$; плотность относительной частоты w_i/h .

6. Построить интервальный вариационный ряд распределения объёмов основных фондов 100 предприятий, млн руб.

Результат группировки приведён на рисунке 2. Контроль: сумма частот равна объёму выборки, $\sum m_i = 100$; сумма относительных частот равна 1.

i	ai	bi	xi	Частота mi	Накопленная частота miH	Относительная частота	Относительная накопленная частота	h
1	4,98	5,09	5,035	2	2	0,02	0,02	0,18
2	5,09	5,20	5,145	3	5	0,03	0,05	0,27
3	5,20	5,31	5,255	12	17	0,12	0,17	1,09
4	5,31	5,42	5,365	19	36	0,19	0,36	1,73
5	5,42	5,53	5,475	29	65	0,29	0,65	2,64
6	5,53	5,64	5,585	18	83	0,18	0,83	1,64
7	5,64	5,75	5,695	12	95	0,12	0,95	1,09
8	5,75	5,86	5,805	5	100	0,05	1	0,45

Рис. 2 – Интервальный вариационный ряд распределения объёмов основных фондов 100 предприятий, млн руб.

7. Построить гистограмму частот

По оси X отложены интервалы, по оси Y частоты m_i ; боковой зазор между столбцами равен 0 %.



Рис. 3 – Гистограмма частот

8. Построить гистограмму относительных частот

Строится аналогично, по оси Y отложены относительные частоты w_i .




Рис. 4 – Гистограмма относительных частот

9. Построить полигон частот интервального ряда

Полигон частот --- ломаная, соединяющая точки $(x_i; m_i)$, где $x_i = (a_i + b_i)/2$ --- середина интервала. Для замыкания ломаной добавлены две точки с нулевой частотой: $x_1 - h = 4,925$ и $x_8 + h = 5,915$. Построен точечной диаграммой с прямыми отрезками и маркерами.



Рис. 5 – Полигон частот

10. Построить кумуляту накопленных относительных частот интервального ряда

Кумулята --- ломаная, соединяющая точки $(b_i; w_i^{\text{нак}})$; в начало добавлена точка $(a_1; 0)$.




Рис. 6 – Кумулята накопленных относительных частот

11. Сделать анализ гистограмм

По гистограммам частот и относительных частот (рисунки 3 и 4), а также по полигону и кумуляте (рисунки 5 и 6) можно сделать следующие выводы.

- 1) **Форма распределения.** Гистограммы одновершинные, провалов и вторых вершин нет, следовательно, совокупность предприятий по объёму основных фондов однородна. Форма близка к колоколообразной, то есть к нормальному распределению.
- 2) **Модальный интервал.** Наибольшая частота ($m_5 = 29$, то есть $w_5 = 0,29$) приходится на интервал 5,42--5,53 млн руб.: около 29 % предприятий имеют объём основных фондов в этих пределах.
- 3) **Симметрия.** Слева от модального интервала находятся $2 + 3 + 12 + 19 = 36$ предприятий, справа --- $18 + 12 + 5 = 35$. В крайних группах картина зеркальная: в трёх крайних левых интервалах $2 + 3 + 12 = 17$ предприятий, в двух крайних правых $12 + 5 = 17$. Гистограмма почти симметрична.
- 4) **Концентрация.** В трёх центральных интервалах (5,31--5,64) сосредоточено $19 + 29 + 18 = 66$ % предприятий. Предприятий с малым объёмом фондов (менее 5,20 млн руб.) и с самым большим (более 5,75 млн руб.) мало: по 5 %.
- 5) **Центр распределения.** Средняя, медиана и мода близки друг к другу: по исходным данным 5,4493; 5,43; 5,43, по интервальному ряду 5,4717; 5,4731; 5,4724 млн руб. Такое совпадение также характерно для симметричных распределений.
- 6) **Полигон и кумулята.** Полигон повторяет форму гистограммы: вершина над серединой модального интервала (5,475), спуск в обе стороны примерно одинаков. Кумулята имеет S-образный вид и растёт быстрее всего на модальном интервале (прирост 0,29). Накопленная частота 0,5 достигается внутри интервала 5,42--5,53, то есть примерно половина предприятий имеет объём основных фондов не более 5,47 млн руб.

Количественно эти выводы подтверждаются коэффициентами асимметрии и эксцесса (п. 13).

12. Вычислить основные числовые характеристики по исходным несгруппированным данным и по вариационному ряду

Характеристики вычислены тремя способами: по исходным данным *по формуле* (с помощью функций СУММПРОИЗВ, СЧЁТ, LN и т. п.), по исходным данным готовыми функциями *MS Excel* и по *интервальному ряду*, где вместо каждого значения берётся середина интервала x_i с весом m_i .

а) средние: арифметическая, гармоническая и геометрическая

Для исходных данных (всего $n = 100$ значений) и для интервального ряда:

$$\bar{x} = \frac{1}{n} \sum_{j=1}^n x_j = \frac{544,93}{100} = 5,4493;$$

$$\bar{x}_{\text{ряд}} = \frac{1}{n} \sum_{i=1}^k x_i m_i = \frac{547,17}{100} = 5,4717;$$

$$\bar{x}_{\text{гарм}} = \frac{n}{\sum_{j=1}^n \frac{1}{x_j}} = \frac{100}{18,3685} = 5,4441;$$

$$\bar{x}_{\text{гарм, ряд}} = \frac{n}{\sum_{i=1}^k \frac{m_i}{x_i}} = \frac{100}{18,2935} = 5,4664;$$

$$\bar{x}_{\text{геом}} = \sqrt[n]{\prod_{j=1}^n x_j} = \sqrt[100]{4,1058 \cdot 10^{73}} = 5,4467;$$

$$\bar{x}_{\text{геом, ряд}} = \sqrt[n]{\prod_{i=1}^k x_i^{m_i}} = \sqrt[100]{6,1851 \cdot 10^{73}} = 5,4691.$$

Формулы Excel: =СУММ(Х)/СЧЁТ(Х) и =СРЗНАЧ(Х); =СЧЁТ(Х)/СУММПРОИЗВ(1/Х) и =СРГАРМ(Х); =EXP(СУММПРОИЗВ(LN(Х))/СЧЁТ(Х)) и =СРГЕОМ(Х). Для всех положительных значений выполняется неравенство $\bar{x}_{\text{гарм}} \leq \bar{x}_{\text{геом}} \leq \bar{x}$, оно выполнено и здесь.

б) медиана и мода

По исходным данным. Медиана при чётном $n = 100$ равна полусумме 50-го и 51-го значений вариационного ряда: $=(\text{НАИМЕНЬШИЙ}(X; 50) + \text{НАИМЕНЬШИЙ}(X; 51))/2 = (5,43 + 5,43)/2 = 5,43$ (функция $=\text{МЕДИАНА}(X)$). Мода --- наиболее часто встречающееся значение: 5,43 млн руб., оно встречается 15 раз (функция $=\text{МОДА.ОДН}(X)$).

По интервальному ряду. Медианный интервал --- первый, где накопленная частота не меньше $n/2 = 50$, то есть 5,42--5,53 ($m_{\text{нак}} = 65$). Модальный интервал --- с наибольшей частотой ($m = 29$), он же 5,42--5,53:

$$\begin{aligned} Me &= a_{Me} + h \frac{\frac{n}{2} - m_{Me-1}}{m_{Me}} \\ &= 5,42 + 0,11 \cdot \frac{50 - 36}{29} = 5,4731, \\ Mo &= a_{Mo} + h \frac{m_{Mo} - m_{Mo-1}}{(m_{Mo} - m_{Mo-1}) + (m_{Mo} - m_{Mo+1})} \\ &= 5,42 + 0,11 \cdot \frac{29 - 19}{(29 - 19) + (29 - 18)} = 5,4724. \end{aligned}$$

Характеристика	По исходным данным		По интервальному ряду
	по формуле	MS Excel	
Характеристики центра группирования			
Средняя арифметическая	5,4493	5,4493	5,4717
Средняя гармоническая	5,4441	5,4441	5,4664
Средняя геометрическая	5,4467	5,4467	5,4691
Медиана	5,43	5,43	5,4731
Мода	5,43	5,43	5,4724

Рис. 7 – Характеристики центра группирования

Значения «по формуле» и в Excel совпадают, что подтверждает правильность расчётов. Небольшое отличие характеристик по интервальному ряду от характеристик по исходным данным вызвано группировкой: внутри интервала все значения заменяются его серединой.

с) начальные и центральные моменты первого, второго, третьего и четвёртого порядков

Начальный момент порядка p : $\nu_p = \frac{1}{n} \sum x_j^p$ (по ряду $\nu_p = \frac{1}{n} \sum x_i^p m_i$).

Центральный момент порядка p : $\mu_p = \frac{1}{n} \sum (x_j - \bar{x})^p$ (по ряду $\mu_p = \frac{1}{n} \sum (x_i - \bar{x})^p m_i$). В Excel по исходным данным: =СУММПРОИЗВ(Х^2)/СЧЁТ(Х) и =СУММПРОИЗВ((Х-СРЗНАЧ(Х))^2)/СЧЁТ(Х); для других порядков меняется показатель степени.

Момент	По исходным данным	По интервальному ряду
Начальный момент 1-го порядка	5,4493	5,4717
Начальный момент 2-го порядка	29,723083	29,968167
Начальный момент 3-го порядка	162,2772698	164,2898097
Начальный момент 4-го порядка	886,8098782	901,5098748
Центральный момент 1-го порядка	0,00000000	0,00000000
Центральный момент 2-го порядка	0,02821251	0,02866611
Центральный момент 3-го порядка	-0,000203263	-0,00071442
Центральный момент 4-го порядка	0,002374418	0,00230344

Рис. 8 – Начальные и центральные моменты

Центральный момент первого порядка равен нулю по свойству средней арифметической (в Excel получается число порядка 10^{-16} из-за погрешности вычислений). Связь моментов: $\mu_2 = \nu_2 - \nu_1^2$.

д) дисперсия и среднее квадратическое отклонение

Дисперсия равна центральному моменту второго порядка, $D = \mu_2$; среднее квадратическое отклонение $\sigma = \sqrt{D}$. По исходным данным:

$$D = 0,028213, \quad \sigma = \sqrt{0,028213} = 0,1680.$$

По интервальному ряду:

$$D_{\text{ряд}} = 0,028666, \quad \sigma_{\text{ряд}} = \sqrt{0,028666} = 0,1693.$$

В Excel дисперсия генеральной совокупности вычисляется функцией =ДИСП.Г(Х) (делит на n).

е) коэффициенты асимметрии и эксцесса

$$As = \frac{\mu_3}{\sigma^3}, \quad Ex = \frac{\mu_4}{\sigma^4} - 3.$$

Функции Excel =СКОС(х) и =ЭКССЕСС(х) используют поправки на объём выборки, поэтому их значения немного отличаются от значений по формулам.

ж) коэффициент вариации

$$V = \frac{\sigma}{\bar{x}} \cdot 100\%.$$

По исходным данным и по интервальному ряду соответственно:

$$V = \frac{0,1680}{5,4493} \cdot 100\% = 3,08\%, \quad V_{\text{ряд}} = \frac{0,1693}{5,4717} \cdot 100\% = 3,09\%.$$

Характеристика	По исходным данным		По интервальному ряду
	по формуле	MS Excel	
Показатели вариации			
Дисперсия	0,02821251	0,02821251	0,02866611
Среднее квадратическое отклонение	0,1679658		0,169310691
Козфициент вариации, %	3,08		3,09
Центральный момент первого порядка	0,00000000		0,00000000
Центральный момент второго порядка	0,02821251		0,02866611
Центральный момент третьего порядка	-0,00020326		-0,00071442
Центральный момент четвертого порядка	0,002374418		0,002303439
Козфициент асимметрии	-0,042894	-0,04355	-0,147197421
Козфициент эксцесса	-0,01685937	0,04475312	-0,196896627

Рис. 9 – Показатели вариации

Коэффициент вариации $V \approx 3\%$ значительно меньше 33%, следовательно, совокупность предприятий однородна по объёму основных фондов, а средняя величина ($\bar{x} \approx 5,45$ млн руб.) хорошо её характеризует.

13. При помощи полученных значений коэффициентов асимметрии и эксцесса проанализировать построенные гистограммы

Для оценки используются следующие правила. *Асимметрия*: $As = 0$ --- распределение симметрично; $As < 0$ --- левосторонняя асимметрия (более длинный «хвост» слева); $As > 0$ --- правосторонняя; при $|As| < 0,25$ асимметрия считается малой. *Эксцесс*: $Ex = 0$ --- островершинность как у нормального распределения; $Ex > 0$ --- более островершинное; $Ex < 0$ --- более плосковершинное. Для проверки существенности отклонений сравниваем показатели с их средними квадратическими ошибками при $n = 100$:

$$\sigma_{As} = \sqrt{\frac{6(n-1)}{(n+1)(n+3)}} = 0,239,$$

$$\sigma_{Ex} = \sqrt{\frac{24n(n-2)(n-3)}{(n-1)^2(n+3)(n+5)}} = 0,464.$$

Если $|As|/\sigma_{As} < 3$ и $|Ex|/\sigma_{Ex} < 3$, отклонение от нормального распределения несущественно.

Показатель	Исходные данные	Интервальный ряд	Ошибка σ
Коэффициент асимметрии As	-0,0429	-0,1472	0,239
$ As /\sigma_{As}$	0,18	0,62	
Коэффициент эксцесса Ex	-0,0169	-0,1969	0,4639339
$ Ex /\sigma_{Ex}$	0,0363	0,4244	

Рис. 10 – Оценка асимметрии и эксцесса

- 1) **Асимметрия.** Коэффициент асимметрии отрицателен, но очень мал по модулю (−0,0429 по исходным данным и −0,1472 по интервальному ряду, оба значения по модулю меньше 0,25), а отношение $|As|/\sigma_{As}$ много меньше 3. Следовательно, асимметрия несущественна: гистограммы (рисунки 3 и 4) практически симметричны, возможна лишь едва заметная левосторонняя скошенность, то есть чуть более длинный «хвост» в области малых объёмов основных фондов. Это согласуется с п. 11: слева от модального интервала 36 предприятий, справа --- 35.
- 2) **Эксцесс.** Коэффициент эксцесса близок к нулю (−0,0169 по исходным данным и −0,1969 по интервальному ряду; $|Ex|/\sigma_{Ex} < 3$). Островершинность гистограмм практически такая же, как у нормального рас-

пределения; по интервальному ряду вершина лишь слегка более пологая ($Ex < 0$). Различие знаков эксцесса в разных способах расчёта (по Excel он равен 0,0448) говорит о том, что отклонение от нуля несущественно и лежит в пределах погрешности группировки.

- 3) **Итог.** Построенные гистограммы одновершинны, почти симметричны и по высоте вершины близки к нормальной кривой. Гипотеза о нормальном распределении объёмов основных фондов предприятий не противоречит данным (в рамках данной работы это оценено визуально и по коэффициентам As и Ex ; формальная проверка критериями согласия не проводилась).

Заключение

В работе выполнена статистическая обработка выборки из 100 значений объёма основных фондов предприятий.

- По формуле Стерджеса построен интервальный вариационный ряд из 8 интервалов длиной 0,11 млн руб.; построены гистограммы частот и относительных частот, полигон частот и кумулята.
- Модальный интервал 5,42--5,53 млн руб. содержит 29% предприятий; в трёх центральных интервалах сосредоточено 66% предприятий.
- Средние по исходным данным: арифметическая 5,4493, гармоническая 5,4441, геометрическая 5,4467 млн руб.; медиана 5,43, мода 5,43 млн руб. По интервальному ряду: 5,4717, 5,4664, 5,4691; 5,4731 и 5,4724 млн руб.
- Дисперсия 0,028213, среднее квадратическое отклонение 0,1680 млн руб., коэффициент вариации 3,08% (3,09% по ряду): совокупность однородна.
- Коэффициенты асимметрии ($-0,0429$) и эксцесса ($-0,0169$) близки к нулю: распределение почти симметрично и близко к нормальному.
- Значения, вычисленные по формулам и функциями Excel, совпали; характеристики по интервальному ряду немного отличаются из-за замены значений серединами интервалов.